



PONTIFICIA UNIVERSIDAD CATÓLICA DE CHILE

EYP2807 — MÉTODOS BAYESIANOS

Informe Final 2

Factores Predictivos del Rendimiento Elite en Powerlifting

*Luna Garcés, Tomás Perez, Tomás Romero,
Christan Camilo, Benjamin Thareau*

Resumen

En siguiente informe se presentaran los resultados del análisis de datos de Powerlifting con el objetivo de identificar los factores predictivos para que un atleta alcance un rendimiento de elite. Durante el proceso de investigación y trabajo se utilizo un Modelo de Regresión Logística Bayesiana para analizar las variables y su relación con el rendimiento elite, definiendo un puntaje elite a partir de un percentil de los puntajes Dots de los atletas.

La principal pregunta a responder a través de este informe es **¿Cuales características del atleta actuan como factores predictivos para alcanzar el nivel de elite en USA?** Al intentar responder esta pregunta surgieron otras, como si el sexo del atleta afecta la probabilidad de alcanzar el nivel elite, o si el tipo de equipamiento utilizado en la competencia tiene alguna influencia en el rendimiento elite.

Introducción

El powerlifting es un deporte de fuerza que consiste en levantamiento de peso principalmente en tres modalidades, sentadilla, press de banca y peso muerto, donde se busca la Repetición Máxima o 1RM, es decir levantar el máximo peso posible en el primer intento. Al tratarse de un deporte de fuerza el rendimiento de los atletas de ve fuertemente influenciado por factores físicos como el peso corporal, por esta razón existen diversos sistemas de puntuación que estandarizan el rendimiento de cada atleta segun estos. Para este informe nos centraremos en el sistema de puntuación Dots (Dynamic Objective Team Scoring), no se abordara ni las formulas de como este se calcula, ni otros sistemas de puntuación, ya que no son relevantes para el objetivo de este informe, que es identificar los factores predictivos del rendimiento elite, definido como el percentil 95 % puntajes Dots (top 5 % de los atletas).

Para modelar el rendimiento elite se utilizo un modelo de regresión logística con enfoque bayesiano, ya que utiliza un enfoque más probabilístico de que ocurra un evento con dos estados posibles, en este caso alcanzar o no el rendimiento elite.

FALTA EXPLICAR COMO SE ELIGIO EL MODELO FINAL, SOLO MENCIONAR LAS TECNICAS UTILIZADAS Y PQ :)

Análisis

Descripción de variables y datos

Los datos utilizados para estimar los modelos provienen de **OpenPowerlifting**, una base abierta que recopila resultados de competencias de powerlifting a nivel internacional. La base original contiene 3.920.662 registros y 42 variables, pero para este análisis fueron seleccionadas ~ 16 variables que están señaladas mas adelante, es importante señalar que las filas no son completamente independientes, ya que un mismo atleta puede aparecer varias veces si compitió en más de una ocasión.

La preparación y tratamiento de los datos estan detalladas de mejor manera en el informe anterior, pero a modo de resumen, antes de modelar los datos se descartaron variables que no eran relevantes y se crearon nuevas variables a partir de las originales, como lo son

- **Elite:** Variable binaria creada para clasificar atletas como Elite (1) si sus puntos *Dots* son $\geq$ al percentil

95 de la muestra, o No Elite (0) en caso contrario.

- **Elite_texto:** Variable categórica de texto (“Elite” o “No elite”) derivada de la variable anterior, utilizada principalmente para simplificar la segmentación en los análisis de frecuencias y representaciones gráficas.
- **Equipo:** Variable cualitativa creada para condensar la columna original *Equipment* en únicamente dos niveles comparables: “Raw” y “Equipado” (esta última agrupa las modalidades de soporte *Wraps*, *Single-ply* y *Multi-ply*).
- **Tested_bin:** Indicadora binaria que simplifica la condición de control antidopaje, asignando un valor de 1 si el atleta compitió bajo una categoría testeada (“Yes”) y 0 si no se realizó la prueba o el dato figuraba como ausente.
- **Year:** Variable cuantitativa discreta que extrae el año exacto de la competencia a partir de la columna original de tipo fecha (*Date*).
- **Age_std, Bw_std y Year_std:** Variables numéricas continuas (edad, peso corporal y año de competencia, respectivamente) transformadas mediante un proceso de estandarización lineal (*Z-score*). Esta conversión centra las medias en 0 y fija la desviación estándar en 1.

Se eliminaron observaciones con valores faltantes en variables utilizadas para modelar y se restringieron valores atípicos en edades, pesos corporales, etc. Quedando con las siguientes variables para el análisis

Cuadro 1: Diccionario de Variables Seleccionadas de OpenPowerlifting

Variable	Descripción	Tipo	Escala/Unidad
Sex	La categoría de sexo en la que compitió el levantador.	Cualitativa	No aplica
Age	La edad del levantador en la fecha de inicio del encuentro.	Cuantitativa	años
AgeClass	La clase de edad en la que se clasifica el levantador.	Cualitativa	Rango de edad
BodyweightKg	El peso corporal registrado del levantador en el momento de la competencia.	Cuantitativa	Kg
Event	El tipo de competencia en la que participó el levantador.	Cualitativa	No aplica
Equipment	La categoría de equipamiento bajo la cual se realizaron los levantamientos.	Cualitativa	No aplica
Tested	“Yes” si el levantador ingresó a una categoría con prueba de drogas.	Cualitativa	No aplica
TotalKg	Suma de los mejores levantamientos si los tres fueron un éxito	Cuantitativa	Kg
Dots	Un número positivo si se pudieron calcular los puntos Dots.	Cuantitativa	Puntos
Date	La fecha de inicio del encuentro en formato ISO 8601.	Fecha	Fecha
Sanctioned	Indica si el encuentro cuenta como oficialmente sancionado.	Cualitativa	No aplica

Continuación de la tabla anterior

Variable	Descripción	Tipo	Escala/Unidad
Elite	Variable binaria creada para clasificar atletas como Elite (1) si sus puntos Dots son $\geq$ al percentil 95 de la muestra, o No Elite (0) en caso contrario.	Cualitativa	Binaria (1/0)
Elite_texto	Etiqueta en formato texto de la clasificación Elite (“Elite” o “No elite”).	Cualitativa	No aplica
Equipo	Variable creada para agrupar las categorías de equipamiento en “Raw” y “Equipado”.	Cualitativa	No aplica
Tested_bin	Variable binaria que indica si el atleta fue sometido a control antidopaje (1 = Yes) o no (0 = No/NA).	Cualitativa	Binaria (1/0)
Sexo	Variable equivalente a Sex, adaptada al español.	Cualitativa	No aplica
Year	Año de la competencia, extraído a partir de Date.	Cuantitativa discreta	Año
Age_std	Edad del atleta estandarizada (Z-score) para el modelamiento bayesiano.	Cuantitativa continua	Desviaciones estándar
Bw_std	Peso corporal del atleta estandarizado (Z-score) para el modelamiento bayesiano.	Cuantitativa continua	Desviaciones estándar
Year_std	Año de la competencia estandarizado (Z-score) para el modelamiento bayesiano.	Cuantitativa continua	Desviaciones estándar

0.1. Análisis preliminar

(aqui yo pondria los graficos antes del modelar)

Modelo preliminar

La variable a modelar es **Elite**, que es una variable binaria, por lo que utilizar un modelo que ajuste este tipo de variables según una probabilidad de pertenecer o no a la categoría es lo más adecuado, por lo que se optó por un modelo de regresión logística bayesiana

$$\text{logit}(P(Y_i = 1 \mid \mathbf{x}_i)) = \log\left(\frac{p_i}{1 - p_i}\right) = \beta_0 + \sum_{j=1}^k \beta_j x_{ij} \quad (1)$$

donde $Y_i \sim \text{Bernoulli}(p_i)$ representa si el atleta i es elite, $\mathbf{x}_i$ es el vector de predictores, β_0 es el intercepto y $\beta_1, \dots, \beta_k$ son los coeficientes asociados a cada predictor, esto se define igual en todos los modelos `family = binomial(link = "logit")`, se optó por la familia binomial ya que cada fila del dataset representa a un solo atleta donde $\text{Bin}(n = 1, p_i)$ es equivalente a $\text{Bernoulli}(p_i)$.

Al estar utilizando un enfoque bayesiano tenemos la posibilidad de elegir las distribuciones *prior*, lo que permite incorporar información previa que ayuda a regularizar las estimaciones de los coeficientes y cuantificar la incertidumbre de forma directa mediante intervalos creíbles y probabilidades como $P(\beta_j > 0)$. En este caso, se optó por las siguientes distribuciones *prior*

Para los **coeficientes** $\beta_1, \dots, \beta_k$ se especificó:

$$\beta_j \sim \mathcal{N}(0, 2.5^2), \quad \text{con } \texttt{autoscale} = \texttt{TRUE} \quad (2)$$

los valores de la normal fueron elegidos segun recomineda la literatura para modelos de regresión logística bayesiana.

EXPLICAR ESTO UN POCO MEJOR :)

Para el **intercepto** β_0 se utilizó una *prior* más amplia:

$$\beta_0 \sim \mathcal{N}(0, 5^2), \quad \text{con } \texttt{autoscale} = \texttt{TRUE} \quad (3)$$

ESTO IGUAL, PQ SE ELIGIO ESTA DISTRIB PARA LOS INTERCEPTOS

Con lo anterior definido se procedió a estimar diferentes modelos con distrintos predictores cada uno

- Modelo 1: Elite ~
- Modelo 2: Elite ~
- Modelo 3: Elite ~
- Modelo 4: Elite ~
- Modelo 5: Elite ~
- Modelo 6: Elite ~

0.2. Modelo Final

1. Resultados y Conclusiones

1.1. Título de subtítulo 3.1

1.2. Título de subtítulo 3.2

2. Conclusiones

Referencias

BayesianN. 2023, “Modeling Car Insurance Claim using Bayesian Logistic : Part 1”, RPubS. Disponible en: <https://rpubs.com/BayesianN/claims>

A Short Intro to Bayesian Logistic Regression <https://medium.com/@wtc2189/day-6-a-short-intro-to-bayesian-logistic-regression>
<https://discourse.mc-stan.org/t/the-prior-in-logistic-model/41077>

Gracias :)